

week 8

▼ 논문리뷰 _ CNN for Biomedical Image Segmentation

사전지식

▼ 이미지 인식하는 방법

- single object


classification : 하나의 이미지를 하나의 클래스로 예측

classification + localization : 하나의 이미지의 클래스와 위치를 예측

- multiple objects

object detection : object에 대해 바운딩박스를 그림

instance segmentation : object에 대해 픽셀마다 클래스를 예측




▼ semantic segmentation : 이미지 내에 있는 각 물체들을 의미있는 단위로 분할하는 작업

일반적인 분류에서는 단일이미지를 하나의 클래스로 분류

분할에서는 각 픽셀마다 하나의 클래스로 분류




이미지가 주어졌을때, (높이 x 너비 x 1) 크기를 가지는 한 장의 분할 맵(segmentation map)을 생성



각 픽셀마다 n 개의 클래스에대한 확률을 뱉어야하므로, 정답은 (높이 x 너비 x n)형태를 지님. 각 픽셀마다 원한 인코딩 형식을 따름


- 단점 : 분할작업을 위한 데이터 세트 생성비용은 매우 비쌈
각 픽셀마다 어떤 클래스로 분류되는지 일일이 지정해야하기에...
- 장점 : 일반적인 CNN 분류 모델의 형식을 크게 바꾸지 않고 학습할 수 있음
딥러닝 네트워크 구조가 크게 어렵지 않은 편임

▼ CNN 동작과정




CNN에서는 필터(=커널)를 사용. 각 필터는 입력에서 특정한 특징을 잡아내어 특징 맵 (feature map)을 생성함


얕은 층에서는 local feature, 깊은 층에서는 global feature를 인식하는 경향이 있음




하나의 필터는 슬라이딩하면서 컨볼루션 연산을 통해 특징 맵을 계산함



입력 이미지의 로컬영역과 필터 사이에서 내적을 계산해 각 위치의 결과를 구함
각 위치에서의 컨볼루션 연산결과를 모아서 특징 맵을 생성함



출력 텐서의 채널크기는 필터의 개수와 동일해야함



CNN레이어는 여러번 중첩되어 사용될 수 있음


CNN 분류 모델에서 깊은레이어로 갈수록 채널의 수가 증가하고, 너비와 높이는 감소하게됨
CNN 분류 모델에서는 중요한 정보는 유지하고, 해상도(너비, 높이)를 감소시키는 방법을 사
용함

→ 가장 큰 값을 가지는 원소만 남기는 max pooling을 가장 많이 사용함

주요내용

▼ U-Net

해상도가 U자 형으로 감소했다가 증가




수축경로 : 이미지에 존재하는 넓은 문맥정보를 처리

확장경로 : 정밀한 지역화가 가능하도록함

▼ convolution 연산 종류

- Down-sampling
- Up-sampling


Down-sampling 목적



Strided Convolution: 너비와 높이가 감소

해상도를 줄이기위한 목적으로 사용됨
stride를 사용함 (분류문제에서 많이 사용)


Up-sampling 목적



Transposed Convolution: 너비와 높이가 증가


$3 \times 3 \rightarrow 5 \times 5$

해상도를 높이기위한 목적으로 사용됨



- 해상도를 줄임 : 채널사이즈는 증가하되, 너비와 높이는 점점 감소시킴. 32x32까지 압축 시킴
convolution 연산과 maxpooling으로 ~
 - 해상도를 증가 : 채널사이즈는 줄이되, 너비와 높이는 점점 증가시킴. 338x338x2 까지 늘림
up convolution 연산 (커널사이즈를 줄여서 계산)
 - feature map은 해상도 감소할때 사용했던 것을 그대로 해상도 증가했을때 적용함
→ 앞쪽에서 사용했던 레이어를 그대로 사용했기에 더 좋은 결과가 나올 수 있음
 - fully connected layer를 사용하지 않음
- ⇒ Fully Convolutional Network (FCN) 아키텍처로 구성되어짐

수축경로




해상도 감소시키는 부분

- 2×2 max pooling을 사용
→ 해상도(너비와 높이) 2배 감소
- conv연산으로 채널크기는 2배 증가
- " Conv연산 → ReLU → Maxpooling " 과정을 반복

앞부분을 인코더로 봄

확장경로




해상도 증가시키는 부분

- 2×2 convolution (up-convolution) 사용
해상도(너비와 높이) 2배 증가
- conv 연산으로 채널크기는 2배 감소
- 수축경로에서 처리된 feature 채널 레벨에서 연결 map을 잘라내어 가져와 수행함

⇒ 학습의 난이도도 쉬워지고, 학습잘됨
단, 앞에 레이어의 해상도를 줄여야 연결가능(너비와 높이가 동일해야하므로)

▼ overlap-tile 전략

타일 겹치기(Overlap-tile) 전략: 타일 A와 타일 B의 일부 영역이 겹칩니다.



U-net 구조상 출력 이미지의 해상도가 입력 이미지보다 작기에 입력이미지를 보다 더 크게 넣어줌

(실제로 노란영역의 segmentation이 필요하면 더 큰 범위의 패치를 삽입)

FCN 특성상 입력 이미지의 해상도에는 제한이 없음.

overlap-tile : 크게 입력이미지를 넣다보니 겹치는 부분이 발생하게 됨

이미지의 경계부분은 extrapolation을 사용함 (미러링 활용)

▼ U-Net 학습방법 : object function

$$p_k(x) = \frac{\exp(a_k(x))}{\sum_{k'=1}^K \exp(a_{k'}(x))}$$

$x \in \Omega$: 픽셀의 위치(pixel position)이며, $\Omega \subset \mathbb{Z}^2$
 k : k 번째 특징 채널(feature channel) = 클래스
 $a_k(x)$: k 번째 채널의 x 위치의 activation 값

U-Net은 segmentation을위한 네트워크이므로, 픽셀단위로 소프트맥스함수를 사용함

$$E = \sum_{x \in \Omega} w(x) \log(p_{l(x)}(x))$$

$l(x)$: 이미지의 x 의 true label

→ 추가적인 가중치(weight) 함수 사용


학습을 위해 다음의 cross-entropy 손실을 사용

• 가중치 함수

$$w(x) = w_c(x) + w_0 \cdot \exp\left(-\frac{(d_1(x) + d_2(x))^2}{2\sigma^2}\right)$$

따라서, 세포와의 거리가 가까우면 가중치(weight)가 증가

$w_c: \Omega \rightarrow \mathbb{R}$: The weight map to balance the class frequencies.
 $d_1: \Omega \rightarrow \mathbb{R}$: The distance to the border of the nearest cell.
 $d_2: \Omega \rightarrow \mathbb{R}$: The distance to the border of the second nearest cell.



세포를 명확히 구분하기 위해 작은 분리경계를 학습함

$w(x)$ 는 인접한 셀 사이에 있는 배경 레이블에 대해 높은 가중치를 부여함

w_c : 클래스의 빈도를 조절

d_1 : 가장 가까운 세포의 경계까지의 거리

d_2 : 두번째로 가까운 세포의 경계까지의 거리

세포와의 거리가 가까우면 가중치가 증가됨 (거리와 가중치가 반비례)

- 데이터 증진기법

논문에서는 data augmentation 기술을 사용함


Elastic Deformation 방법도 사용함

▼ Experiments


Rank	Group name	Warping Error	Rand Error	Pixel Error
	** human values **	0.000005	0.0021	0.0010
1.	u-net	0.000353	0.0382	0.0611
2.	DIVE-SCI	0.000355	0.0305	0.0584
3.	IDSIA [1]	0.000420	0.0504	0.0613
4.	DIVE	0.000430	0.0545	0.0582
	⋮			
10.	IDSIA-SCI	0.000653	0.0189	0.1027

Warping error를 기준으로 정렬한 결과 U-Net이 우수한 정확도를 보이는 것을 확인

PHC-U373 : 35개의 부분적으로 주석이있는 학습 이미지 데이터 세트



DIC-HeLa : 20개의 부분적으로 주석이있는 학습 이미지 데이터 세트



⇒ 노란색 테두리인 정답에 모두 다 근사한 정확도를 보임

Name	PhC-U373	DIC-HeLa
IMCB-SG (2014)	0.2669	0.2935
KTH-SE (2014)	0.7953	0.4607
HOUS-US (2014)	0.5323	-
second-best 2015	0.83	0.46
u-net (2015) [*]	0.9203	0.7756

두드러진 IOU 점수 향상

→ 이전보다 더 우수한 IOU값을 보임