

week 9

▼ Multi-Layer Fully Connected Neural Networks

- 질문 1

3layer network 와 5layer network 훈련들 중 상대적으로 더 어려웠던것은?

(어떤 네트워크가 초기화 규모에 더 민감한가?)

⇒ 답변 : 5 layer network가 더 어려워보임. 여기에서는 50개의 샘플로 훈련하기에 과대적합되기 쉬운 상황. 이렇게 제한된 샘플을 사용할때는 더 많은 가중치를 가진 네트워크를 훈련시키기가 더 어려움

즉, 5 layer network는 가중치 초기화 규모에 더 민감함

- 질문 2

AdaGrad로 네트워크를 훈련할때 업데이트가 매우 작아지고, 네트워크가 느린 이유는 무엇일까요?

Adam도 비슷할까요?

AdaGrad, like Adam, is a per-parameter optimization method that uses the following update rule:


```
cache += dw**2  
w += - learning_rate * dw / (np.sqrt(cache) + eps)
```

⇒ 답변 : dw의 제곱은 cache의 제곱근으로 나누어 추가되기에 업데이트에 영향을 줌. 반복횟수가 많아지면서 cache가 매우 커지므로 업데이트가 매우 작아지게됨. 이로인해 결국 네트워크가 느리게 학습하게 됨

▼ Batch Normalization

- 질문 3


가중치 초기화 척도는 배치 정규화가 있거나 없는 모델에 어떻게 다른 영향을 미치나요?



⇒ 답변 : BN이 있는 8계층 네트워크와 BN이 없는 네트워크를 훈련함. 가중치 초기화 규모의 대부분의 숫자에서 BN 네트워크는 일반적으로 더 큰 최고의 검증 및 훈련정확도를 가짐. BN 네트워크의 최종 훈련 손실은 원래 네트워크의 훈련손실보다 작은 경향이 있음.

• 질문 4

배치 정규화와 배치 크기 간의 관계는 무엇을 의미하는가?



⇒ 답변 : 배치크기가 50인 BN이 전체적으로 가장 높은 정확도를 지님. 배치 크기가 50이 될때까지 배치크기가 클수록 정확도가 더 좋아지는 경향이 있음. 특히, 배치크기가 5인 경우 BN 네트워크의 결과는 동일한 배치크기를 가진 원래 네트워크보다 일부 에포크에서는 더 나쁨. ← BN이 동일한 배치의 샘플을 사용하여 평균과 분산을 계산하기에..

⇒ 배치 크기가 너무 작으면 계산된 평균과 분산이 전체 데이터를 나타내긴 어려움

• 질문 5

다음 데이터 전처리 단계 중 배치정규화와 유사한 단계는 무엇이며, 레이어 정규화와 유사한 단계는 무엇인가?

1. Scaling each image in the dataset, so that the RGB channels for each row of pixels within an image sums up to 1.
2. Scaling each image in the dataset, so that the RGB channels for all pixels within an image sums up to 1.
3. Subtracting the mean image of the dataset from each image in the dataset.
4. Setting all RGB values to either 0 or 1 depending on a given threshold.

⇒ 답변 : 배치정규화와 유사한 단계는 2번과 3번 / 레이어 정규화와 유사한 단계는 1번

1번) 이미지 내의 **각 픽셀** 행에대한 RGB채널의 합이 1이 되도록 데이터세트의 각 이미지 크기를 조정

2번) 이미지 내의 **모든 픽셀**에 대한 RGB 채널의 합이 1이 되도록 데이터세트의 각 이미지 크기를 조정

3번) 데이터세트의 각 이미지에서 데이터세트의 평균 이미지를 뺀

4번) 주어진 임계값에 따라 모든 RGB 값을 0 또는 1로 설정

- 질문 6

다음 중 레이어정규화가 제대로 작동하지 않을 경우는 무엇인가?

1. Using it in a very deep network
 2. Having a very small dimension of features
 3. Having a high regularization term

⇒ 답변 : 2번, 3번

1번, 레이어정규화는 배치정규화의 단점을 극복하고 모델에서 더 나은 성능을 발휘함

2번, 레이어정규화는 특징과 관련해 정규화를 수행함. 특성에대한 평균과 분산도 계산함. 단, 특성 차원이 작은 경우 평균과 분산을 도출하는 데 사용되는 샘플 수가 적기에 평균과 분산이 데이터를 잘 설명하지 못할 수 있음. → 레이어정규화의 성능저하로 이어지게됨

3번, 레이어정규화는 모델에 이미 높은 정규화 항이 있는 경우 레이어정규화를 추가하면 성능이 저하될 수 있음

▼ Dropout

- 질문 7

역 드롭아웃을 통해 전달되는 값을 드롭아웃 레이어에서 'p'로 나누지않으면 어떻게 되는가?


⇒ 답변 : 훈련 시간에 사용된 입력이 출력에 어떤 영향을 미치는지 살펴보아야함. p개의 입력량을 유지하므로 훈련에는 $p \times$ 입력만 사용됨. 이런 이유로 훈련시간동안 출력이 취소됨

테스트 시간에는 모든 뉴런이 활성상태를 유지함. 이는 네트워크 취소뉴런을 훈련시켰기에 문제가 발생함

→ 이러한 문제를 해결하기위해 훈련시간에 결과를 p로 나누어 크기를 조정함

- 질문 8

드롭아웃이 있는 경우와 없는 경우의 검증 및 훈련정확도를 비교하세요. 정규화 도구로써 드롭아웃의 결과는 어떤 의미인가요?



⇒ 답변 : 드롭아웃을 사용하지 않을 때 훈련정확도가 더 좋음. 그러나 드롭아웃이 있는 검증정확도는 없는 검증정확도보다 더 나은 경향이 있음. 드롭아웃을 사용하면 훈련정확도와 검증정확도 사이의 차이를 줄일 수 있음. 즉, 과적합을 해결해줌.

→ 드롭아웃은 정규화 도구로 사용될 수 있음